Redes de Kohonen e Ensembles

Aulas 10 e 11 · Da auto-organização topológica aos comitês preditivos

Introdução ao Aprendizado de Máquina · Teoria e Implementação

Mentor Prof. Cloves Rocha



Made with GAMMA

Fundamentos · Motivação

Por que combinar e organizar modelos?

Um modelo isolado pode simplificar demais (alto viés) ou oscilar com ruídos (alta variância).

1 Dados sem rótulo precisam de estrutura

Identificar padrões e agrupar dados sem anotações humanas.

---

2 Comitês de decisão erram menos

Modelos compensam falhas uns dos outros e estabilizam previsões.

---

3 Roteiro das aulas

Mapas de Kohonen (SOM), Bagging, Boosting, Stacking e laboratório comparativo em Python.



Made with GAMMA



Aula 10 · Aprendizado Não Supervisionado

Redes de Kohonen aprendem sem rótulos

O **Self-Organizing Map (SOM)** é uma rede neural artificial inspirada no córtex somatossensorial humano. Em vez de prever uma classe conhecida, o SOM mapeia espaços com dezenas de dimensões em uma grade visual bidimensional contínua.

Preservação de Topologia

Amostras com características semelhantes são projetadas em neurônios vizinhos na grade, mantendo a geometria dos dados.

Redução Dimensional

Comprime tabelas multidimensionais em um mapa 2D intuitivo sem calcular matrizes de covariância complexas.

Teuvo Kohonen, 1982: neurônios competem pelo dado e cooperam na adaptação de pesos.

Made with GAMMA

Algoritmo Competitivo · Dinâmica de Ajuste

Como o SOM treina: quatro etapas essenciais

1

Amostragem

Um vetor aleatório da base de treino é apresentado à grade de neurônios.

2

Competição (BMU)

Calcula-se a distância euclidiana. O neurônio com pesos mais próximos é a Best Matching Unit.

3

Cooperação

A BMU e seus vizinhos imediatos na grade física são puxados na direção da amostra.

4

Decaimento

O raio de vizinhança e a taxa de aprendizado encolhem exponencialmente a cada época.

A fórmula de atualização: $w_i(t+1) = w_i(t) + \theta(i, \mathrm{BMU}, t) \cdot \alpha(t) \cdot (x - w_i(t))$*, onde o raio* θ *contrai a grade.*

Made with GAMMA

Aula 11 · Paradigma Supervisionado

Ensembles: a sabedoria do grupo

Um ensemble combina modelos simples ou instáveis em um preditor composto mais forte e preciso.

O teorema de Condorcet ilustra a base estatística: se cada classificador independente acerta mais de 50%, a decisão por maioria tende à perfeição à medida que o grupo cresce.

Bagging	Boosting	Stacking
Modelos em paralelo	Modelos em série, cada um corrige o anterior	Um meta-modelo combina diferentes famílias algorítmicas
Reduz variância, suaviza ruídos e evita overfitting	Reduz viés e subajuste, focando exemplos difíceis	Aprende a melhor combinação das previsões

Made with GAMMA

Técnica Paralela · Redução de Variância

Bagging: modelos independentes em paralelo

Bootstrap Aggregating treina vários estimadores de forma totalmente independente sobre réplicas estatísticas geradas a partir do conjunto de dados original.

01

Amostragem Bootstrap

Criam-se B subconjuntos de tamanho N sorteados com reposição. Cerca de 63,2% dos dados únicos entram em cada réplica.

02

Treino Concorrente

Cada estimador-base (geralmente árvores profundas) é treinado isoladamente, viabilizando paralelismo computacional massivo.

03

Agregação Coletiva

Na predição final: votação majoritária para problemas de classificação ou cálculo da média aritmética para regressão.

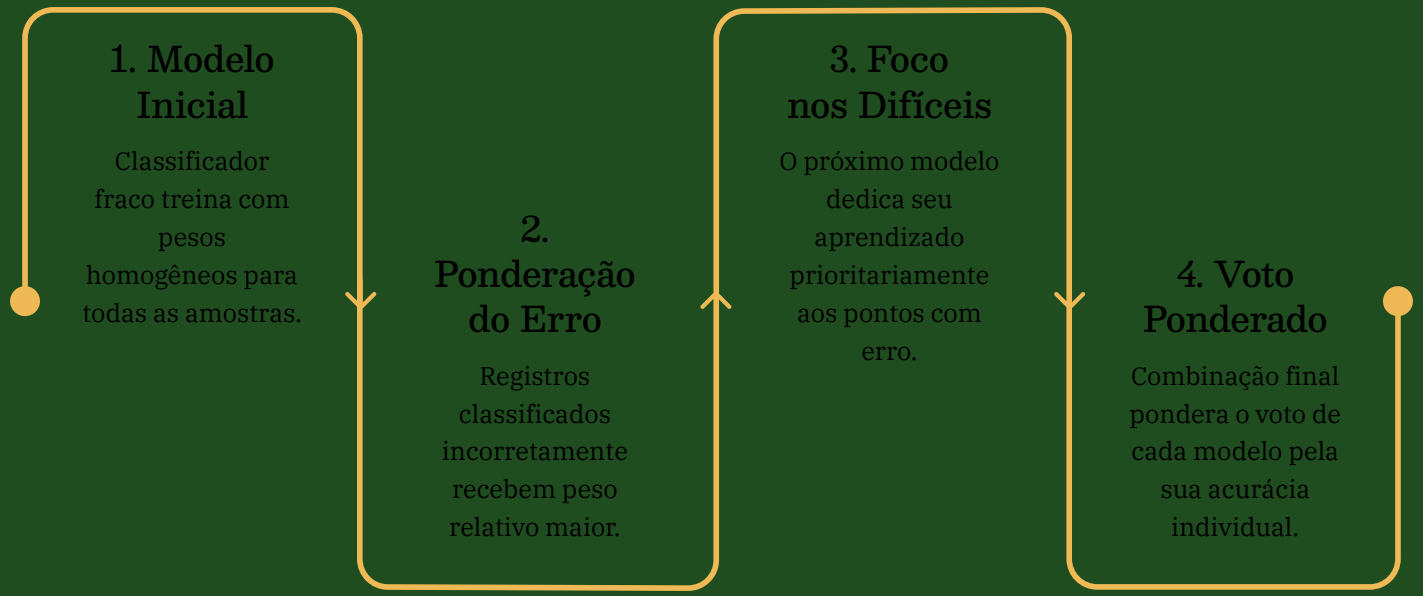
Exemplo emblemático: ***Random Forest*** *adiciona aleatoriedade aos atributos sorteados em cada nó, descorrelacionando as árvores.*

Made with GAMMA

Técnica Sequencial · Redução de Viés

Boosting: aprender progressivamente com os erros

Diferente do Bagging, os modelos no Boosting operam em fila encadeada: cada novo regressor ou classificador foca nos resíduos não explicados pelos predecessores.



Algoritmos fundamentais: AdaBoost (ajusta pesos de amostras) e Gradient Boosting / XGBoost (ajusta resíduos via gradiente descendente).

Made with GAMMA

Arquitetura em Camadas · Meta-aprendizado

Stacking: um modelo que aprende a combinar previsões

Em vez de média ou votação fixas, modelos-base geram previsões que um meta-modelo aprende a combinar para cada tipo de entrada.

NÍVEL 1 · MODELOS-BASE

Random Forest: captura padrões não lineares densos.
SVM RBF: constrói fronteiras de margem máxima.
KNN: avalia contiguidade local imediata.

NÍVEL 2 · META-MODELO

Regressão Logística ou Ridge treina sobre as previsões geradas e aprende sua melhor combinação.

Validação Out-of-Fold: evita vazamento de dados no treino do nível 2.

Atenção metodológica: usar sempre K-Fold no nível 1 para produzir as features do nível 2, impedindo memorização artificial.

Made with GAMMA

Hands-on · Laboratório Experimental

Desafio técnico em Python

Use um único dataset tabular para todos os métodos: Breast Cancer ou Wine.

Etapa 1 · Exploração SOM

Com **MiniSom**, visualize agrupamentos e densidade sem rótulos, pela U-Matrix.

Grade 10 × 10; `sigma=1.0`, `learning_rate=0.5` e 1000 iterações com `X_scaled`.

Etapa 2 · Torneio de Ensembles

No scikit-learn, compare **BaggingClassifier**, **AdaBoostClassifier** e **StackingClassifier**.

Bagging e AdaBoost: 50 estimadores, `random_state=42`. Stacking: RandomForestClassifier e SVC (`probability=True`), com LogisticRegression como meta-modelo.

Avalie acurácia média em 5 folds, desvio-padrão de estabilidade e tempo de treinamento.

Made with GAMMA

O que levar das Aulas 10 e 11

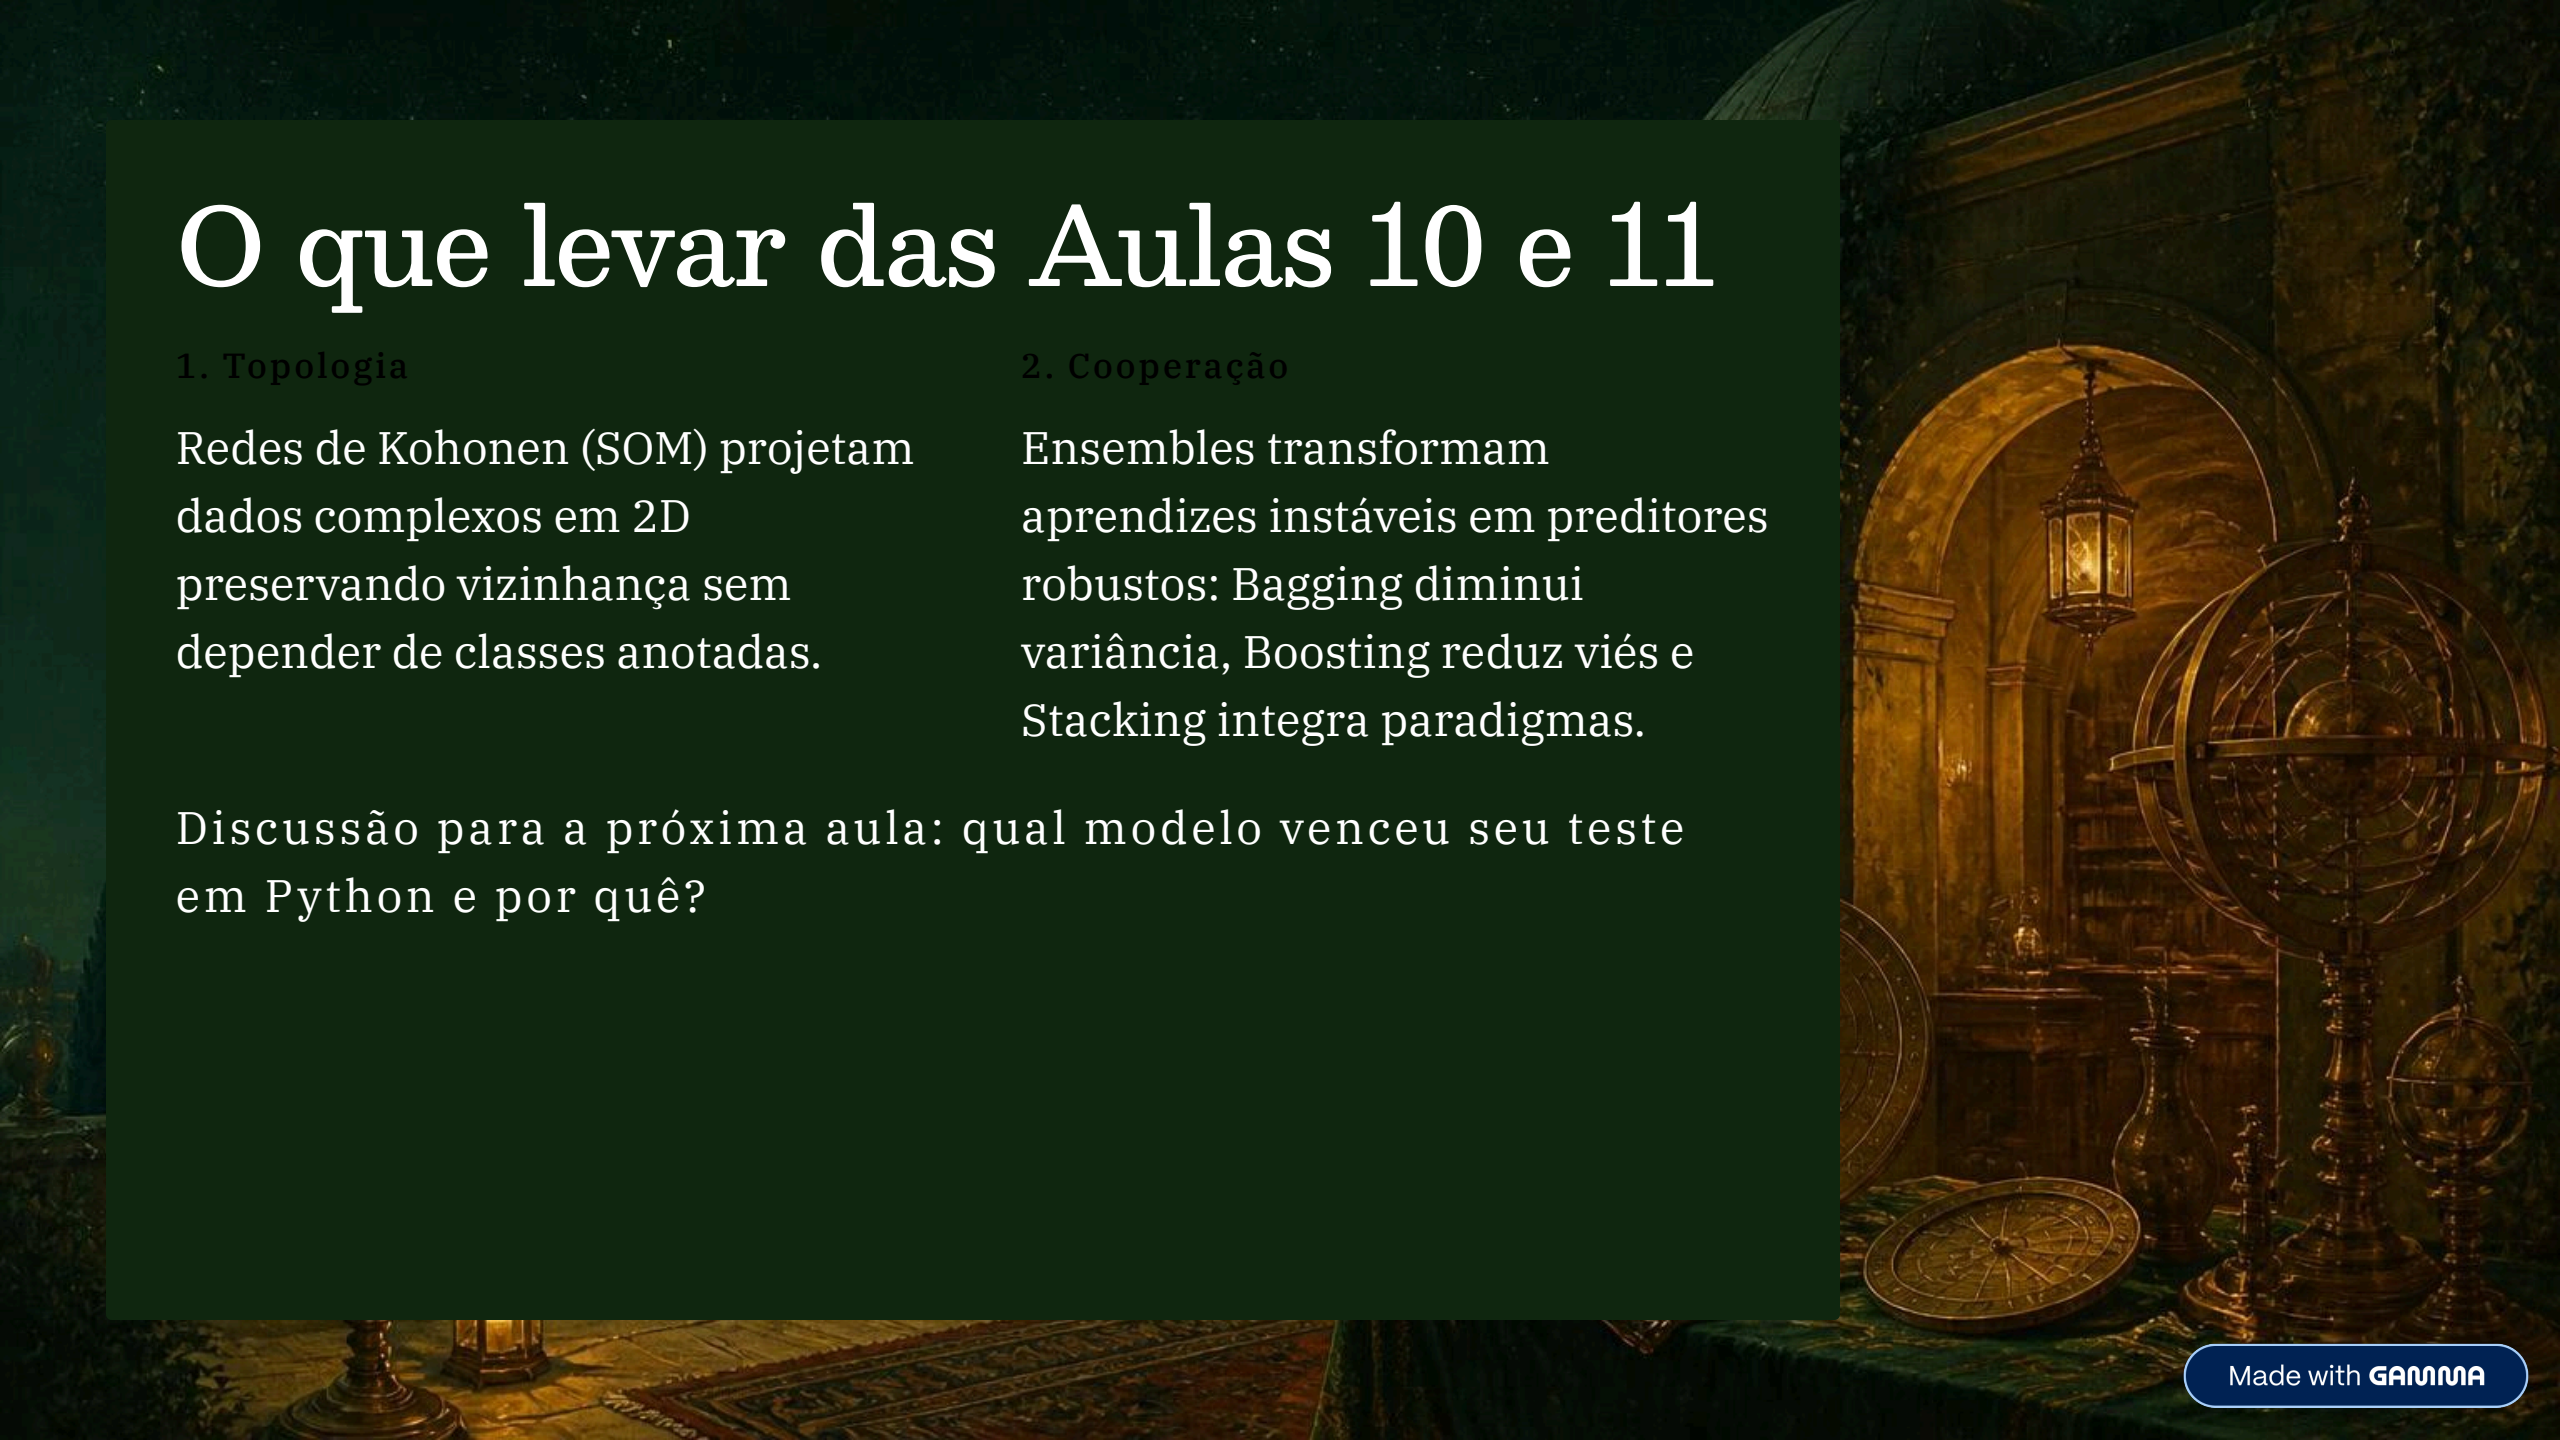
1. Topologia

Redes de Kohonen (SOM) projetam dados complexos em 2D preservando vizinhança sem depender de classes anotadas.

2. Cooperação

Ensembles transformam aprendizes instáveis em preditores robustos: Bagging diminui variância, Boosting reduz viés e Stacking integra paradigmas.

Discussão para a próxima aula: qual modelo venceu seu teste em Python e por quê?



Made with GAMMA