
Redes Neurais Artificiais | PML e SOM




1.


Neurônio biológico

Estrutura do Neurônio

- ▷ Dendritos
- ▷ Corpo celular
- ▷ Axônio




Sinapse Nervosa



Redes Neurais Biológicas

- ▷ Propagação do impulso nervoso



2.


Redes Neurais Artificiais



São técnicas computacionais que possuem modelos matemáticos inspirados na estrutura neural biológica e simulam seu processo de aprendizagem.

McCulloch e Pitts (1943)


- ▷ [Paper de McCulloch e Pitts](#)



$$y = \varphi\left(\sum_{n=1}^N \omega_n x_n + b\right)$$

Activation Functions

▷ Exemplos de funções de ativação




Step Function:

$$f(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1/2 & \text{se } x = 0 \\ 1 & \text{se } x > 0 \end{cases}$$

Activation Functions

▷ [Exemplos de funções de ativação](#)




Logistic Function ou Sigmoid:


$$f(x) = \frac{1}{1 + e^{-(x)}}$$

Perceptron de Rosenblatt (1958)

- ▷ [New York Times Article, 1958](#)
- ▷ [Perceptrons Applied to Images \(video\)](#)



Perceptron at the Cornell Aeronautical Laboratory, Buffalo, New York, circa 1960.




Primeira máquina física utilizando algoritmos de aprendizagem de máquina.

Histórico das RNAs

- ▷ [1943] Primeiro modelo do neurônio (McCulloch & Pitts);
- ▷ [1949] Primeiras regras de aprendizado (Hebb);
- ▷ [1958] Proposto o modelo do “Perceptron” (Rosenblatt);
- ▷ [1958 - 1969] Sucesso do Perceptron (em circuitos eletrônicos) motiva estudos sobre o tema;
- ▷ [1969] Perceptron de uma única camada é incapaz de solucionar problemas não linearmente separáveis;
- ▷ [1969 a 1980] Poucos trabalhos desenvolvidos na área;
- ▷ [1980 - 1990] Algoritmos de treinamento para redes de múltiplas camadas de neurônios (Paul Werbos);
- ▷ [Atualmente] As redes neurais são utilizadas e exploradas com sucesso em diversas aplicações.

Exemplo Operador “and”:


- ▷ Atribuindo o valor do peso para 0,5.



x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1

Exemplo Operador “or”:


- ▷ Atribuindo o valor do peso para 1,1.



x1	x2	y
0	0	0
0	1	1
1	0	1
1	1	1

Exemplo Operador “xor”:

▷ Como resolver nesse caso?



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

3.


Multi Layer Perceptron (MLP)



O perceptron multicamadas é semelhante ao perceptron tradicional, mas possui camadas entre as entradas e o(s) neurônio(s) de saída.

Estrutura dos MLPs


- ▷ Camada de entrada;
- ▷ Conexões com pesos;
- ▷ Camadas escondidas;
- ▷ Feedforward;
- ▷ Camadas de saída.



Treinamento dos PMLs


- ▷ Supervisionados (compara as saídas);
- ▷ Inicializa os pesos com valores entre 0 e 1 (geralmente são utilizados algoritmos random com “seed”);
- ▷ Gradient Descent (busca da combinação de pesos para minimizar, quanto for possível, o erro nas saídas);
- ▷ Back Propagation (algoritmo de ajuste dos pesos da camada de saída até a primeira camada oculta);
- ▷ Learning Rate (multiplicador na velocidade de aprendizado);

Como resolver o caso do XOR?














x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Solução para XOR:



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Para problemas não-lineares


Structure	Types of Decision Regions	Exclusive-OR Problem	Classes with Meshed regions	Most General Region Shapes
Single-Layer 	<i>Half Plane Bounded By Hyperplane</i>			
Two-Layer 	<i>Convex Open Or Closed Regions</i>			
Three-Layer 	Arbitrary (Complexity Limited by No. of Nodes)			

Aplicações das MLPs

Modelos estocásticos.





Modelo com regressão linear.



Aplicações das MLPs


Funções de aproximação universal



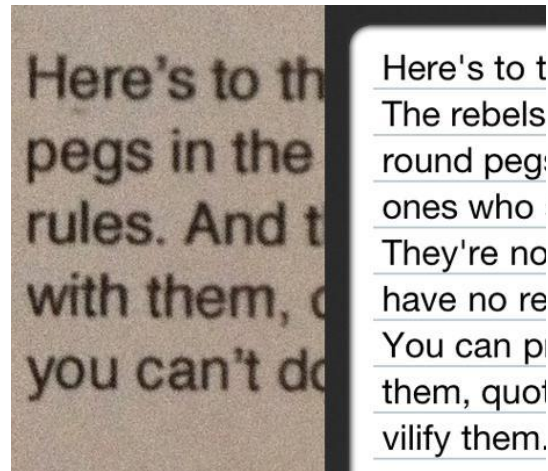
Aplicações das MLPs



Reconhecimento de voz.



Reconhecimento de imagens.



Reconhecimento de caracteres.

4.


Self Organized Map (SOM)



SOMs foi proposta por Teuvo Kohonen e pode ser considerado um tipo de redes neurais, mas tem um treinamento não supervisionado e possui uma abordagem competitiva para os ajustes de pesos.


Estrutura dos SOMs

- ▷ Camada de entrada;
- ▷ Conexões com pesos;
- ▷ Camadas de saída (bidimensionais).




Treinamento dos SOMs


- ▷ Inicialização dos pesos (subespaço compreendido entre os maiores vetores);
- ▷ Alimentada com vetores representativos (várias iterações);
- ▷ Aprendizado competitivo (para cada iteração, os pesos são computados através da distância euclidiana);
- ▷ Best Matching Unit (BMU);
- ▷ BMU e outros neurônios próximos são ajustados para o vetor de entrada;




Treinamento dos SOMs



Aplicações das SOMs



Clusterização



Redução dimensional


Por que utilizar RNAs?

- ▷ Generalizar (saídas para entradas inconsistentes);
- ▷ Imunidade a ruído (saídas para entradas com variações);
- ▷ Flexibilidade (funciona em situações inéditas);
- ▷ Adaptabilidade (ajusta-se com o tempo);
- ▷ Não-linearidade (utilização de multi camadas);
- ▷ Robustez (tolerância a falhas);
- ▷ Fácil hibridização (algoritmos de busca e otimização);
- ▷ Fácil implementação;
- ▷ Problemas muito complexos;
- ▷ Funções de aproximadores universais.

Desvantagens

- ▷ Recurso computacional;
- ▷ Bons hardwares;
- ▷ Tempo elevado no treinamento;
- ▷ Trabalha com valores numéricos;
- ▷ Pré-processamento dos dados;
- ▷ Grande volume de dados;
- ▷ Resultados desconcertantes.

TED - Juan Enriquez: A era da maravilha genética



Fonte: https://www.ted.com/talks/juan_enriquez_the_age_of_genetic_wonder_feb_2019

Obrigado! Thank you!

Dúvidas???



```
<?php  
print("ACESSO AO MATERIAL");
```

```
<?php  
print("http://slideshare.net/ClovesRocha");
```



Atribuição-NãoComercial 3.0 Brasil
(CC BY-NC 3.0 BR)



UNIFG
LAUREATE INTERNATIONAL UNIVERSITIES*



LAUREATE
INTERNATIONAL
UNIVERSITIES*

